

Ejercicio 01 · Dataset público y SVM

Marlenis Judith Concepción Cuevas · INF-8239-C2 · Unidad I

Dataset propuesto: Ionosphere (UCI). Aprobación docente pendiente.

Repositorio: [abrir carpeta del ejercicio en GitHub](#)

Modelo	Conjunto	F1 macro	Accuracy	Recall b	Recall g
Baseline	entrenamiento	0.391	0.643	0.000	1.000
Baseline	validacion	0.391	0.643	0.000	1.000
Baseline	prueba	0.391	0.643	0.000	1.000
SVM	entrenamiento	0.984	0.986	0.973	0.993
SVM	validacion	0.953	0.957	0.920	0.978
SVM	prueba	0.938	0.943	0.920	0.956

Dataset y selección

Ionosphere (UCI): 351 registros, 34 atributos numéricos, clasificación g/b, CC BY 4.0. Alternativa: Banknote Authentication, 1372 registros y 4 atributos. Se propone Ionosphere por su dimensionalidad; aprobación pendiente. La ficha completa y las fuentes están en `reports/seleccion_dataset.md`.

Auditoría y protocolo

Un duplicado eliminado; 0 faltantes; atributo_02 constante. División estratificada 210/70/70, semilla 42. El identificador de fila solo documenta la partición y no entra en el modelo. Búsqueda de 12 combinaciones y cinco pliegues sobre entrenamiento. Validación y prueba no ajustan transformaciones. SHA256 y diccionario en reports. Prueba reservada para evaluación posterior a la selección.

Conclusión

El experimento examinó si un pipeline SVM podía clasificar retornos de radar y superar una regla constante. Se utilizó Ionosphere, procedente de UCI y distribuido con licencia CC BY 4.0. La comparación previa con Banknote Authentication favoreció provisionalmente Ionosphere porque sus 34 atributos permiten estudiar posteriormente reducción dimensional. Esta selección sigue pendiente de aprobación docente; la ejecución técnica no sustituye ese requisito académico.

La auditoría identificó 351 registros originales, ningún valor faltante y un duplicado exacto. Se retiró ese duplicado antes de particionar para impedir que una observación idéntica apareciera en conjuntos diferentes. Quedaron 350 registros: 210 para entrenamiento, 70 para validación y 70 para prueba. Se mantuvo una columna constante, cuyo escalamiento es manejado por el pipeline, para conservar el esquema original. La clase objetivo se separó de los predictores y los índices de las particiones quedaron registrados.

La búsqueda comparó kernels lineal y RBF con validación cruzada estratificada de cinco pliegues exclusivamente sobre entrenamiento. La imputación y el escalamiento se ajustaron dentro de cada pliegue. La configuración seleccionada fue rbf, con $C=10$ y $\gamma=\text{scale}$. El baseline predijo siempre la clase mayoritaria. En prueba, su F1 macro fue 0.391, mientras que el SVM alcanzó 0.938, una diferencia de 0.546. La exactitud del SVM fue 0.943; se priorizó F1 macro para representar ambas clases.


El F1 macro descendió de 0.984 en entrenamiento a 0.953 en validación y 0.938 en prueba. Esta diferencia exige cautela frente al sobreajuste, aunque no elimina la mejora respecto a la referencia. Hubo 4 errores entre las 70 observaciones de prueba. El recall fue 0.920 para retornos malos y 0.956 para buenos; la matriz de confusión permite distinguir los errores en ambas direcciones. Sin información adicional de adquisición no se puede atribuir causalmente cada fallo a una característica concreta.

Los resultados respaldan continuar con la comparación de ensambles, pero no garantizan desempeño fuera de este radar histórico. El pequeño tamaño de prueba limita la precisión de las estimaciones y no se calculó un intervalo de confianza. La descarga verificada, las semillas, las pruebas y el código reutilizable facilitan reproducir el procedimiento.

Fuentes

Sigillito, Wing, Hutton y Baker (1989), Ionosphere: <https://doi.org/10.24432/C5W01B>. Lohweg (2012), Banknote Authentication: <https://doi.org/10.24432/C55P57>. Documentación de scikit-learn sobre pipelines y prevención de fuga: https://scikit-learn.org/stable/common_pitfalls.html.

Matriz de confusión del SVM en prueba



Pruebas automatizadas (15, todas aprobadas)

#	Prueba	Qué comprueba	Por qué se hizo
1	test particiones sin solapamiento y con cobertura	Entrenamiento, validación y prueba no comparten filas, cubren todo el conjunto, tienen las dos clases y se repiten igual.	Base de toda la evaluación: sin esto habría fuga o resultados no reproducibles.
2	test escalador no usa datos de evaluacion	El escalador aprende la media solo de entrenamiento y no cambia al predecir datos nuevos.	Evita fuga de información de validación o prueba hacia el modelo.
3	test esquema target y duplicados	Las 34 columnas son las esperadas, el target no está entre los predictores y no quedan duplicados.	Contrato de datos antes de entrenar.
4	test pipeline admite faltantes sin reajustar	El pipeline predice aunque aparezca un valor faltante.	Robustez ante datos incompletos en uso real.
5	test descarga rechaza archivo alterado	Un archivo con SHA256 distinto al documentado se rechaza.	Garantiza que siempre se usan los mismos datos de UCI.
6	test duplicado eliminado antes de partir	Hay 351 registros originales y 350 después de quitar el único duplicado.	Un duplicado podría quedar a la vez en entrenamiento y en prueba.
7	test codificación del target respeta las clases originales	Las cantidades de b=0 y g=1 coinciden con las etiquetas originales.	Un error al codificar invertiría el significado de todas las métricas.
8	test tamanos y estratificación de la particion	La partición es 210/70/70 y cada parte mantiene la proporción de clases.	Comparar particiones solo tiene sentido si están equilibradas.
9	test pipeline tiene pasos y parametros esperados	El pipeline tiene imputar → escalar → SVM y respeta kernel y C.	La búsqueda de hiperparámetros depende de estos nombres.

#	Prueba	Qué comprueba	Por qué se hizo
10	test columna constante no produce valores invalidos	La columna constante no genera valores infinitos o NaN al escalar.	La auditoría detectó una columna constante y se decidió conservarla.
11	test entrenamiento es reproducible	Dos entrenamientos con la misma semilla dan exactamente las mismas puntuaciones.	Reproducibilidad exigida por el mandato.
12	test metricas acotadas y perfectas con prediccion perfecta	Las seis métricas existen, están entre 0 y 1 y valen 1 con predicción perfecta.	Comprueba la función de métricas que alimenta la tabla del PDF.
13	test particiones guardadas coinciden con el codigo	El archivo particiones.csv coincide con la partición que produce el código.	La evidencia guardada es la que realmente se usó.
14	test parametros elegidos son el mejor rango de la validacion cruzada	Los parámetros guardados son los de rango 1 en la búsqueda con validación cruzada.	Demuestra que la elección no se hizo mirando la prueba.
15	test svm supera al baseline en prueba	El F1 macro del SVM en prueba supera al del baseline por más de 0.4.	Responde la pregunta del ejercicio con la evidencia guardada.