

Ejercicio 03 · Corpus público y clasificador de texto reproducible

Marlenis Judith Concepción Cuevas · INF-8239-C2 · Unidad II · Docente: Edwin Ramón José Nolasco

Repositorio: <https://github.com/marlenis-concepcion/CienciaDatosUasd2026/tree/main/Ciencia%20de%20DatosII/Unidad%20II/Ejercicio%2003>


1. Corpus, licencia y pregunta

Corpus: SMS Spam Collection v.1 (UCI 228), Almeida y Gómez Hidalgo, 2011. Licencia CC BY 4.0. DOI 10.24432/C5CC84. Descarga automática con verificación SHA-256 del ZIP original. Se comparó con Sentiment Labelled Sentences (UCI 331, CC BY 4.0, 3000 frases balanceadas); se eligió SMS Spam porque tiene desbalance real y duplicados, lo que permite evaluar métricas por clase y prevención de fuga.

Pregunta: ¿puede un clasificador TF-IDF separar spam de mensajes legítimos con un F1 macro claramente superior a una línea base, sin que los mensajes repetidos inflen el resultado?

2. Auditoría y prevención de fuga

5574 mensajes, sin nulos; 4827 ham (86.6 %) y 747 spam (13.4 %). Se encontraron 403 duplicados exactos y 434 al normalizar minúsculas, dígitos y espacios, sin etiquetas contradictorias. Se eliminaron **antes** de partir: quedan 5140 mensajes. La partición es estratificada 70/15/15 con semilla 42, y una prueba automática comprueba que ningún texto normalizado se repite entre particiones. El TF-IDF se ajusta dentro del pipeline, solo con entrenamiento.





3. Línea base y dos pipelines comparables

Línea base: clase más frecuente. Pipelines: TF-IDF + Complement Naive Bayes y TF-IDF + regresión logística (class_weight='balanced'). Ambos usan la misma rejilla de TF-IDF (unigramas o bigramas, min_df 1 o 2) y la misma validación cruzada estratificada de 5 pliegues sobre entrenamiento. Mejor configuración: Naive Bayes (unigramas y bigramas, min_df=1, alpha=0.1) y regresión logística (unigramas y bigramas, min_df=1, C=10.0). **Decisión:** F1 macro en validación; desempate por recall de spam, registrada antes de evaluar en prueba. Resultado: naive_bayes.

Modelo	F1 macro CV	F1 macro valid.	F1 macro test	Accuracy test	Precisión spam	Recall spam	ms/texto	Tamaño KB
dummy	—	0.4675	0.468	0.879	0.000	0.000	0.011	862
naive_bayes	0.961	0.9544	0.976	0.990	0.957	0.957	0.012	2356
logistic	0.964	0.9539	0.969	0.987	0.946	0.946	0.014	1161

Validación: 771 mensajes (94 spam). Prueba: 771 mensajes (93 spam).

4. Evaluación



Naive Bayes comete 4 falsos positivos y 4 falsos negativos en prueba (precisión y recall de spam 0.957). La diferencia con la regresión logística es pequeña: esta ganó en validación cruzada (0.964 frente a 0.961), perdió en validación por 0.0005 y ordena ligeramente mejor los mensajes según la curva precisión-recall (AP 0.99 frente a 0.98). No hay evidencia suficiente para afirmar que un pipeline sea superior.

5. Análisis de 23 errores

Se analizaron los 8 errores del modelo elegido en prueba y los 15 en validación. Cada mensaje se leyó y se clasificó; el detalle con explicación está en reports/error_analysis.csv.

Categoría	Errores	Ham → spam	Spam → ham
Etiqueta dudosa de la fuente	7	0	7
Vocabulario comercial en mensaje legítimo	7	7	0
Texto corto con palabras poco frecuentes	4	4	0
Spam con tono personal	2	0	2
Spam sin señales típicas	2	0	2
Fragmento de mensaje dividido	1	0	1

id	Real → pred.	Texto	Explicación
3890	ham → spam	Unlimited texts. Limited minutes.	"Unlimited texts" y "minutes" son términos de ofertas de telefonía; aquí describen un plan en una conversación normal.
1430	spam → ham	For sale - arsenal dartboard. Good condition but no doubles or trebles!	Parece un anuncio personal de venta y no un SMS masivo; probablemente es texto copiado de un comentario del foro Grumbletext.
1269	spam → ham	Can U get 2 phone NOW? I wanna chat 2 set up meet Call me NOW on 09096102316 U can cum here 2moro Luv JANE xx	Mismo patrón que el id 1458 (número 090..., "Calls£1/min"); el modelo no aprendió que los números premium son una señal fuerte porque cada número es un token distinto.
3742	spam → ham	2/2 146tf150p	Es la segunda parte ("2/2") de un SMS largo y solo trae un código de tarifa; sin la primera parte no hay contexto.

Lectura: 7 errores son mensajes etiquetados como spam que en realidad son comentarios del foro de origen (ruido de etiqueta). Otros 7 son mensajes legítimos con vocabulario comercial (free, offer, phone). Los números de tarificación especial no se aprovechan porque cada número es un token distinto; un rasgo que los agrupe sería una mejora concreta.

6. Conclusión y límites

TF-IDF con un clasificador lineal resuelve bien este corpus (F1 macro 0.976 frente a 0.468 de la línea base) y el resultado no depende de duplicados, porque se eliminaron antes de partir. El techo lo marcan la calidad de las etiquetas y la antigüedad del corpus: el modelo no debe usarse en mensajería actual ni en español sin reentrenarlo y sin revisión humana.

7. Uso de IA

Utilicé Claude Code (Claude Opus 5.5) para adaptar el proyecto base, escribir pruebas, el cuaderno y la redacción. Verifiqué licencias y DOI en UCI, la composición del corpus en su readme, el SHA-256 y la reproducibilidad de las métricas; se corrigió la descripción de las fuentes del corpus y una prueba mal construida. Detalle, prompts y correcciones en docs/DECLARACION_IA.md.