

Ejercicio 03 · Corpus público y clasificador de texto reproducible

Marlenis Judith Concepción Cuevas · INF-8239-C2 · Unidad II · Docente: Edwin Ramón José Nolasco

Repositorio: <https://github.com/marlenis-concepcion/CienciaDatosUasd2026/tree/main/Ciencia%20de%20DatosII/Unidad%20II/Ejercicio%2003>


1. Corpus, licencia y pregunta

Corpus: SMS Spam Collection v.1 (UCI 228), Almeida y Gómez Hidalgo, 2011. Licencia CC BY 4.0. DOI 10.24432/C5CC84. Descarga automática con verificación SHA-256 del ZIP original. Se comparó con Sentiment Labelled Sentences (UCI 331, CC BY 4.0, 3000 frases balanceadas); se eligió SMS Spam porque tiene desbalance real y duplicados, lo que permite evaluar métricas por clase y prevención de fuga.

Pregunta: ¿puede un clasificador TF-IDF separar spam de mensajes legítimos con un F1 macro claramente superior a una línea base, sin que los mensajes repetidos inflen el resultado?

2. Auditoría y prevención de fuga

5574 mensajes, sin nulos; 4827 ham (86.6 %) y 747 spam (13.4 %). Se encontraron 403 duplicados exactos y 434 al normalizar minúsculas, dígitos y espacios, sin etiquetas contradictorias. Se eliminaron **antes** de partir: quedan 5140 mensajes. La partición es estratificada 70/15/15 con semilla 42, y una prueba automática comprueba que ningún texto normalizado se repite entre particiones. El TF-IDF se ajusta dentro del pipeline, solo con entrenamiento.





3. Línea base y dos pipelines comparables

Línea base: clase más frecuente. Pipelines: TF-IDF + Complement Naive Bayes y TF-IDF + regresión logística (class_weight='balanced'). Ambos usan la misma rejilla de TF-IDF (unigramas o bigramas, min_df 1 o 2) y la misma validación cruzada estratificada de 5 pliegues sobre entrenamiento. Mejor configuración: Naive Bayes (unigramas y bigramas, min_df=1, alpha=0.1) y regresión logística (unigramas y bigramas, min_df=1, C=10.0). **Decisión:** F1 macro en validación; desempate por recall de spam, registrada antes de evaluar en prueba. Resultado: naive_bayes.

Modelo	F1 macro CV	F1 macro valid.	F1 macro test	Accuracy test	Precisión spam	Recall spam	ms/texto	Tamaño KB
dummy	—	0.4675	0.468	0.879	0.000	0.000	0.011	862
naive_bayes	0.961	0.9544	0.976	0.990	0.957	0.957	0.012	2356
logistic	0.964	0.9539	0.969	0.987	0.946	0.946	0.014	1161

Validación: 771 mensajes (94 spam). Prueba: 771 mensajes (93 spam).

4. Evaluación



Naive Bayes comete 4 falsos positivos y 4 falsos negativos en prueba (precisión y recall de spam 0.957). La diferencia con la regresión logística es pequeña: esta ganó en validación cruzada (0.964 frente a 0.961), perdió en validación por 0.0005 y ordena ligeramente mejor los mensajes según la curva precisión-recall (AP 0.99 frente a 0.98). No hay evidencia suficiente para afirmar que un pipeline sea superior.

5. Análisis de 23 errores

Se analizaron los 8 errores del modelo elegido en prueba y los 15 en validación. Cada mensaje se leyó y se clasificó; el detalle con explicación está en `reports/error_analysis.csv`.

Categoría	Errores	Ham → spam	Spam → ham
Etiqueta dudosa de la fuente	7	0	7
Vocabulario comercial en mensaje legítimo	7	7	0
Texto corto con palabras poco frecuentes	4	4	0
Spam con tono personal	2	0	2
Spam sin señales típicas	2	0	2
Fragmento de mensaje dividido	1	0	1

id	Real → pred.	Texto	Explicación
3890	ham → spam	Unlimited texts. Limited minutes.	"Unlimited texts" y "minutes" son términos de ofertas de telefonía; aquí describen un plan en una conversación normal.
1430	spam → ham	For sale - arsenal dartboard. Good condition but no doubles or trebles!	Parece un anuncio personal de venta y no un SMS masivo; probablemente es texto copiado de un comentario del foro Grumbletext.
1269	spam → ham	Can U get 2 phone NOW? I wanna chat 2 set up meet Call me NOW on 09096102316 U can cum here 2moro Luv JANE xx	Mismo patrón que el id 1458 (número 090..., "Calls£1/min"); el modelo no aprendió que los números premium son una señal fuerte porque cada número es un token distinto.
3742	spam → ham	2/2 146tf150p	Es la segunda parte ("2/2") de un SMS largo y solo trae un código de tarifa; sin la primera parte no hay contexto.

Lectura: 7 errores son mensajes etiquetados como spam que en realidad son comentarios del foro de origen (ruido de etiqueta). Otros 7 son mensajes legítimos con vocabulario comercial (free, offer, phone). Los números de tarificación especial no se aprovechan porque cada número es un token distinto; un rasgo que los agrupe sería una mejora concreta.

6. Pruebas automatizadas

13 pruebas, todas aprobadas (`reports/pruebas.txt`): 6 del proyecto base y 7 propias sobre duplicados, fuga, selección del modelo y análisis de errores. Lista completa en `docs/PRUEBAS.md`.

#	Prueba	Qué comprueba	Por qué se hizo
1	test accepts valid dataframe <i>Proyecto base · Auditoría</i>	Un DataFrame con texto y etiqueta válidos pasa la validación sin error.	Asegura que la validación no rechaza datos correctos; si lo hiciera bloquearía todo el flujo.
2	test rejects missing target <i>Proyecto base · Auditoría</i>	Falla con un mensaje claro si falta la columna objetivo.	Sin la etiqueta no se puede entrenar; es mejor detenerse que entrenar con una columna equivocada.
3	test rejects empty text <i>Proyecto base · Auditoría</i>	Falla si hay textos vacíos.	Un texto vacío no aporta información y distorsiona TF-IDF y las métricas.
4	test each pipeline predicts one label <i>Proyecto base · Baseline y pipelines</i>	Los tres pipelines (línea base, Naive Bayes y logística) entrenan y devuelven una predicción, y todos tienen los pasos tfidf y model.	Confirma que los tres modelos comparados tienen la misma estructura; así la comparación es justa.
5	test tokenize normalizes and removes one character tokens <i>Proyecto base · Reproducibilidad</i>	La tokenización pasa a minúsculas y elimina tokens de una letra.	Documenta cómo se normaliza el texto; si cambiara sin aviso cambiarían los resultados.
6	test demo network has valid pagerank <i>Proyecto base · Reproducibilidad</i>	El PageRank de la red de demostración suma 1 y cada valor está entre 0 y 1.	Comprueba que el entorno de LAB06 funciona; no forma parte de la evaluación de este ejercicio.
7	test deduplicate removes normalized copies before split <i>Nueva · Duplicados y fuga</i>	"Call 0800 NOW" y "call 0999 now" se reconocen como el mismo mensaje y se conserva solo el primero.	El corpus tiene 403 duplicados exactos y 31 más que solo difieren en mayúsculas, números o espacios; si no se eliminan, la misma plantilla de spam puede quedar en entrenamiento y en prueba.
8	test deduplicate rejects contradictory labels <i>Nueva · Duplicados y fuga</i>	Si un mismo texto aparece como ham y como spam el proceso se detiene.	Una etiqueta contradictoria indica un error de datos; eliminarla en silencio ocultaría el problema. En este corpus hay 0 casos, y la prueba garantiza que se detectarían.
9	test splits are disjoint complete and stratified <i>Nueva · Prevención de fuga</i>	Entrenamiento, validación y prueba no comparten filas, entre las tres cubren todo el corpus y cada una mantiene la proporción de spam.	Si una fila estuviera en dos particiones la evaluación sería optimista; si se perdieran filas o cambiara la proporción la comparación dejaría de ser válida.
10	test leakage check detects normalized duplicate across splits <i>Nueva · Prevención de fuga</i>	El control de fuga detecta dos mensajes que solo difieren en números y mayúsculas aunque estén en particiones distintas.	Demuestra que la verificación que se ejecuta en cada corrida sí encuentra la fuga que se quiere evitar.
11	test vectorizer learns vocabulary only from training texts <i>Nueva · Prevención de fuga</i>	Una palabra que solo aparece en el texto de prueba no entra al vocabulario TF-IDF.	Si TF-IDF se ajustara con todos los datos, el modelo conocería palabras e IDF de la prueba antes de evaluarse; el pipeline lo evita y la prueba lo demuestra.
12	test choose ignores baseline and breaks ties by spam recall <i>Nueva · Evaluación</i>	La regla de selección nunca elige la línea base y, si hay empate en F1 macro, prefiere el modelo con mayor recall de spam.	La decisión se toma en validación antes de ver la prueba; la prueba fija esa regla para que no se pueda ajustar después según el resultado.
13	test every analyzed error has category and explanation <i>Nueva · Análisis de 20 errores</i>	Hay al menos 20 errores clasificados, sin ids repetidos y todos con categoría y explicación.	La rúbrica exige analizar 20 errores; la prueba evita entregar errores sin interpretar.

7. Conclusión y límites

TF-IDF con un clasificador lineal resuelve bien este corpus (F1 macro 0.976 frente a 0.468 de la línea base) y el resultado no depende de duplicados, porque se eliminaron antes de partir. El techo lo marcan la calidad de las etiquetas y la antigüedad del corpus: el modelo no debe usarse en mensajería actual ni en español sin reentrenarlo y sin revisión humana.

8. Uso de IA

Utilicé Claude Code (Claude Opus 5.5), Codex (OpenAI) y DeepSeek como apoyo. Con Claude Code adapté el proyecto base y escribí las pruebas, el cuaderno y la redacción. Verifiqué licencias y DOI en UCI, la composición del corpus en su readme, el SHA-256 y la reproducibilidad de las métricas; se corrigió la descripción de las fuentes del corpus y una prueba mal construida. Detalle, prompts y correcciones en docs/DECLARACION_IA.md.