

Ejercicio 04 · Clasificador visual con CNN y Model Card

Marlenis Judith Concepción Cuevas · INF-8239-C2 · Unidad II · Docente: Edwin Ramón José Nolasco

Repositorio: <https://github.com/marlenis-concepcion/CienciaDatosUasd2026/tree/main/Ciencia%20de%20DatosII/Unidad%20II/Ejercicio%2004>


1. Auditoría y partición reproducible

Fashion-MNIST (Xiao, Rasul y Vollgraf, 2017; licencia MIT), cargado con tf.keras. 60,000 imágenes de entrenamiento y 10,000 de prueba de 28×28, balanceadas (6000 y 1000 por clase). La auditoría por hash no encontró duplicados en entrenamiento (0), ni en prueba (0), ni imágenes de entrenamiento repetidas en prueba (0). La validación son 6000 imágenes estratificadas del entrenamiento oficial (semilla 42, índices guardados); la prueba oficial se usó una sola vez, después de fijar la decisión.



2. Línea base y CNN

Se comparan la clase más frecuente, el modelo denso y la CNN pequeña del proyecto base, y una CNN propia que sustituye el promedio global por Flatten + Dense(128). Todos usan Adam, lotes de 128 y parada temprana sobre la pérdida de validación (paciencia 2), con un máximo de 30 épocas. Con las 8 épocas del proyecto base, la CNN pequeña obtuvo F1 0.785 en prueba, por debajo del denso; las curvas muestran que no había convergido.



3. Costo, tamaño y decisión técnica

Modelo	F1 valid.	F1 test	Accuracy test	Parámetros	Épocas	Entrenamientos	Inferencia ms/img	Tamaño KB
Línea base	0.018	0.018	0.100	0	—	—	—	—
Denso (base)	0.888	0.876	0.877	50,890	28	10.9	0.008	619
CNN pequeña (base)	0.854	0.847	0.850	19,466	30	188.2	0.028	262
CNN Flatten	0.926	0.919	0.920	421,642	12	86.8	0.032	4980


Regla fijada antes de la prueba: menos parámetros entre los modelos a menos de 0.01 del mejor f1 macro de validación. F1 macro de validación máximo 0.9263; dentro de la tolerancia 0.01: cnn_flatten. Se elige el de menos parámetros: cnn_flatten. La CNN Flatten gana +0.04 de F1 macro frente al denso, a cambio de 8 veces más parámetros, 4 veces más inferencia y 5 MB en disco. En CPU (Apple M1 Pro, TensorFlow 2.21) la inferencia sigue por

debajo de 0.1 ms por imagen, por lo que el costo es aceptable.


4. Métricas, curvas y errores por clase

Clase	Precisión	Recall	F1	Errores
T-shirt/top	0.849	0.909	0.878	91
Trouser	0.985	0.991	0.988	9
Pullover	0.889	0.854	0.871	146
Dress	0.918	0.931	0.925	69
Coat	0.861	0.897	0.879	103
Sandal	0.990	0.978	0.984	22
Shirt	0.807	0.728	0.766	272
Sneaker	0.928	0.990	0.958	10
Bag	0.983	0.982	0.982	18
Ankle boot	0.988	0.939	0.963	61

Real	Predicha	Errores
Shirt	T-shirt/top	118
Shirt	Coat	69
T-shirt/top	Shirt	63
Pullover	Coat	62
Ankle boot	Sneaker	56



Primer error de prueba por clase real



Shirt es la clase más débil (recall 0.728): se confunde con T-shirt/top, Coat y Pullover, prendas con la misma silueta a 28×28 píxeles. Los errores de calzado (Ankle boot → Sneaker) son el otro grupo relevante. Trouser, Bag, Sandal y Sneaker superan 0.95 de F1.

5. Model Card, pruebas y reproducibilidad

La Model Card (MODEL_CARD.md) documenta uso previsto, usos fuera de alcance, datos, métricas por clase, costo, límites y monitoreo. Hay 9 pruebas (normalización, forma, contrato de salida de los tres modelos, partición estratificada y reproducible, detección de fuga por hash, regla de decisión y conteo de errores). Los modelos guardados reproducen las métricas al recargarlos en el cuaderno.

6. Uso de IA

Utilicé Claude Code (Claude Opus 5.5), Codex (OpenAI) y DeepSeek como apoyo. Con Claude Code adapté el proyecto base, propuse la CNN Flatten y escribí las pruebas, el cuaderno y la redacción. Verifiqué la corrida de 8 épocas, la reproducción de métricas desde los modelos guardados, la partición y las pruebas; se corrigió la regla de decisión y la partición de validación. Detalle en docs/DECLARACION_IA.md.