


Ejercicio 05 · Motor recomendador reproducible

Marlenis Judith Concepción Cuevas · INF-8239-C2 · Unidad III · Docente: Edwin Ramón José Nolasco

Repositorio: <https://github.com/marlenis-concepcion/CienciaDatosUasd2026/tree/main/Ciencia%20de%20DatosII/Unidad%20III/Ejercicio%2005>

1. Datos, licencia y auditoría

MovieLens ml-latest-small (GroupLens; Harper y Konstan, 2015, DOI 10.1145/2827872). Uso para investigación, no comercial y con cita; **no se redistribuye**: data/ está fuera de Git y el script descarga el ZIP y verifica su SHA-256. 100,836 valoraciones de 610 usuarios sobre 9,724 películas (1996-03-29 a 2018-09-24); densidad 1.7 %; sin nulos ni duplicados usuario-película. Cola larga: el 10 % de películas más valoradas reúne el 60 % de las valoraciones y 3,446 películas tienen una sola.



2. Corte temporal y usuarios fríos

Se reservan 61 usuarios (10 %, semilla 42) que no entran al entrenamiento. Para los 549 restantes, por usuario: 70 % más antiguo entrenamiento, 10 % siguiente validación, 20 % más reciente prueba: 63,101 / 9,023 / 18,027 valoraciones. Una prueba automática verifica que el pasado de cada usuario queda en entrenamiento y el futuro en prueba. Relevante = rating $\geq$ 4. En la prueba final se reentrena con entrenamiento + validación.

3. Popularidad, contenido y factorización

Popularidad: media ponderada por número de valoraciones. Contenido: perfil TF-IDF de géneros ponderado por el rating del usuario. Factorización: SGD del proyecto base; los factores y las épocas se eligen por NDCG@10 en validación. Más épocas bajan el RMSE pero empeoran el ranking: predecir bien el rating no equivale a ordenar bien.


Factores	Épocas	NDCG@10 valid.	RMSE valid.	Segundos
10	12	0.0497	0.9759	4.4
20	12	0.0429	0.9612	4.6
40	12	0.0427	0.9528	4.6
20	30	0.0257	0.9119	11.5

4. Tabla principal: ranking, cobertura, novedad e híbrido

Modelo	NDCG@10 valid.	Pareto	NDCG@10 test	Precision@10	Recall@10	Hit@10	Cobertura	Novedad
popularidad	0.0425	no	0.0577	0.0443	0.0352	0.274	0.007	2.29
contenido	0.0093	no	0.0107	0.0090	0.0098	0.086	0.101	6.19
factorizacion	0.0497	no	0.0616	0.0527	0.0401	0.308	0.066	2.69
hibrido_a0.25	0.0164	sí	0.0249	0.0178	0.0161	0.146	0.152	5.51
hibrido_a0.5	0.0363	sí	0.0459	0.0383	0.0276	0.257	0.130	3.98
hibrido_a0.75	0.0527	sí	0.0587	0.0484	0.0360	0.291	0.089	3.03

RMSE de la factorización en prueba: 0.994. El 93.3 % de los ítems relevantes de prueba está en el catálogo recomendable; el resto son películas nuevas que ningún modelo colaborativo puede recomendar.

5. Híbrido y decisión Pareto



Regla fijada en validación: Pareto en validación (NDCG@10 y cobertura); mayor cobertura con NDCG $\geq$ 95% del máximo. Frontera de Pareto: hibrido_a0.25, hibrido_a0.5, hibrido_a0.75. NDCG@10 máximo 0.0527; con al menos 95% de ese valor: hibrido_a0.75. Se elige el de mayor cobertura: hibrido_a0.75. En prueba la factorización queda ligeramente por encima en NDCG (0.062 frente a 0.059), pero el híbrido recomienda un 35 % más del catálogo y con más novedad. Se mantiene la decisión de validación: cambiarla después de ver la prueba sería ajustar el modelo a la prueba.

6. Usuarios fríos y errores

Escenario (61 usuarios fríos)	NDCG@10	Hit@10	Cobertura
popularidad (0 valoraciones)	0.227	0.672	0.0013
contenido (5 valoraciones)	0.080	0.295	0.0445
popularidad sin repetir (5 valoraciones)	0.238	0.689	0.0015

Sin historial, el fallback es la popularidad. Con 5 valoraciones iniciales, el contenido basado solo en géneros no la supera, así que el fallback se mantiene hasta que el usuario acumule historial. Estos valores no se comparan con los de usuarios cálidos, porque la verdad incluye toda la historia del usuario.

Actividad	Usuarios	Historial mediano	NDCG@10	Hit@10	Sin aciertos
Q1 (menos activos)	139	21	0.020	0.108	124
Q2	129	42	0.056	0.279	93
Q3	132	90	0.053	0.280	95
Q4 (más activos)	133	288	0.108	0.504	66

Usuario	Historial	Géneros que le gustan	Géneros recomendados	Géneros relevantes en test
147	16	Comedy, Drama, Action	Drama, Comedy, Crime	Adventure, Comedy, Sci-Fi
189	16	Drama, Crime, Action	Crime, Drama, Action	Adventure, Action, Drama
194	16	Comedy, Drama, War	Comedy, Drama, Action	Musical, Romance, Action

El error se concentra en los usuarios con menos historia: 124 de 139 del cuartil menos activo no reciben ningún acierto. Los ejemplos muestran el patrón: el modelo recomienda los géneros del pasado del usuario, pero en el periodo de prueba sus gustos cambian (aventura, ciencia ficción, musical), algo que ni el contenido ni la factorización anticipan.

7. Límites

Evaluación offline con valoraciones explícitas: no mide clics ni satisfacción real. Solo se usan géneros como contenido. Una sola semilla. La popularidad reforzada por el sistema puede aumentar la concentración del catálogo. System Card en docs/SYSTEM_CARD.md y Dataset Card en docs/DATASET_CARD.md.

8. Pruebas automatizadas

13 pruebas, todas aprobadas (reports/pruebas.txt): 7 del proyecto base y 6 propias. Una de ellas detectó un error real que se corrigió. Lista completa en docs/PRUEBAS.md.

#	Prueba	Qué comprueba	Por qué se hizo
1	test valid contract <i>Proyecto base · Datos, licencia y auditoría</i>	Un conjunto con las columnas y rangos esperados pasa la validación.	Asegura que la validación no bloquea datos correctos.
2	test rejects orphan rating <i>Proyecto base · Datos, licencia y auditoría</i>	Falla si hay una valoración de una película que no existe en movies.csv.	Una valoración huérfana no tiene géneros ni título y rompería el modelo de contenido.
3	test content excludes query and returns unique items <i>Proyecto base · Popularidad, contenido y factorización</i>	El recomendador por contenido no devuelve la propia película consultada ni repite películas.	Recomendar lo que el usuario acaba de ver o repetir ítems infla la lista sin aportar nada.
4	test popularity contains weighted score <i>Proyecto base · Popularidad, contenido y factorización</i>	La popularidad calcula una puntuación ponderada por cantidad de valoraciones.	Evita que una película con una sola valoración de 5 estrellas encabece la lista.
5	test temporal split keeps last event <i>Proyecto base · Corte temporal</i>	En la partición del proyecto base la prueba contiene el evento más reciente de cada usuario.	Evaluar con el futuro y entrenar con el pasado evita usar información que no existiría en el momento de recomendar.
6	test matrix factorization predicts finite value <i>Proyecto base · Popularidad, contenido y factorización</i>	La factorización entrena y predice un número finito.	Detecta divergencias del SGD (valores infinitos o NaN).
7	test ranking metrics <i>Proyecto base · Ranking, cobertura y usuarios fríos</i>	Hit rate y cobertura coinciden con un cálculo manual.	Las métricas de ranking son la base de la decisión.
8	test temporal split keeps past in train and future in test <i>Nueva · Corte temporal</i>	Para cada usuario, todo el entrenamiento es anterior a la validación y esta anterior a la prueba; no se pierden ni se repiten valoraciones.	El corte 70/10/20 por usuario es la base de toda la evaluación; si mezclara pasado y futuro, las métricas serían optimistas.
9	test cold users are reproducible and disjoint from training <i>Nueva · Ranking, cobertura y usuarios fríos</i>	Los usuarios fríos son siempre los mismos con semilla 42 y ninguno aparece en el entrenamiento.	Si un usuario frío tuviera historial en entrenamiento no sería frío y la evaluación del fallback no valdría.
10	test ranking metrics match hand calculation <i>Nueva · Ranking, cobertura y usuarios fríos</i>	Precision@k, recall@k, NDCG@k y acierto coinciden con un ejemplo calculado a mano.	NDCG premia que el acierto esté arriba en la lista; la prueba confirma la fórmula antes de usarla para decidir.
11	test novelty is higher for less popular items <i>Nueva · Ranking, cobertura y usuarios fríos</i>	Recomendar una película poco valorada da más novedad que una muy popular.	La novedad se usa para mostrar el sesgo de popularidad; debe crecer en la dirección correcta.
12	test recommendations exclude seen items and cold user gets popularity <i>Nueva · Híbrido y usuarios fríos</i>	Ningún método recomienda películas ya vistas, aunque se pidan más de las disponibles, y un usuario desconocido recibe la lista de popularidad.	Esta prueba encontró un error real: con pocas películas sin ver, la lista se rellenaba con películas ya vistas. Se corrigió el código.
13	test pareto front and decision rule <i>Nueva · Híbrido y decisión Pareto</i>	La frontera de Pareto excluye un modelo dominado en NDCG y cobertura, y la regla elige el de mayor cobertura con $NDCG \geq 95\%$ del máximo.	La decisión final se toma con esta regla en validación antes de ver la prueba; la prueba evita cambiarla después.

9. Uso de IA

Utilicé Claude Code (Claude Opus 5.5), Codex (OpenAI) y DeepSeek como apoyo. Con Claude Code diseñé la partición temporal y los usuarios fríos, extendí el proyecto base con métricas de ranking, novedad, Pareto e híbridos, y escribí las pruebas, el cuaderno y la redacción. Verifiqué la licencia y la cita en el README de MovieLens, el SHA-256, las pruebas y que la corrección del error no alteró las métricas. Detalle en docs/DECLARACION_IA.md.

Herramienta	Modelo	Uso en esta práctica	Para qué sirve	Límite y control
Claude Code (Anthropic)	Claude Opus 5.5	Usado. Agente en VS Code: código, pruebas, cuaderno, documentación, ejecución y PDF	Tareas largas de varios pasos sobre un repositorio	Todo se verificó con pruebas y reportes
Claude (Anthropic)	Claude Sonnet 5	No usado	Programación cotidiana, equilibrio velocidad-calidad	Menos profundidad en tareas largas
Claude (Anthropic)	Claude Haiku 4.5	No usado	Tareas rápidas y baratas: resúmenes, clasificación	No indicado para diseño experimental
Codex (OpenAI)	Modelo de OpenAI orientado a código (familia GPT-5-Codex)	Apoyo complementario	Proponer y revisar código, explicar errores, sugerir pruebas	Se acepta solo si pasa las pruebas
DeepSeek	DeepSeek-V3 (chat)	Apoyo complementario	Explicar conceptos y revisar redacción	Puede inventar referencias: se verificaron en la fuente
DeepSeek	DeepSeek-R1 (razonamiento)	No usado; recomendado para revisar la lógica de métricas	Razonamiento paso a paso y depuración lógica	No sustituye la ejecución

Reparto de responsabilidades

Responsabilidad	Quién
Valores del análisis (daño prioritario, tolerancias, compuertas, decisiones de uso)	La autora
Elección de datos y verificación de licencias y referencias	La autora, con apoyo de las herramientas
Borradores de código, pruebas y redacción	Herramientas de IA
Ejecución de pruebas y comprobación de cada cifra contra reports/	La autora, con Claude Code
Defensa oral y respuesta a preguntas técnicas	La autora