

Ejercicio 06 · VAE, evaluación y Model Card

Marlenis Judith Concepción Cuevas · INF-8239-C2 · Unidad III · Docente: Edwin Ramón José Nolasco

Repositorio: <https://github.com/marlenis-concepcion/CienciaDatosUasd2026/tree/main/Ciencia%20de%20DatosII/Unidad%20III/Ejercicio%2006>

1. Datos, particiones y líneas base

Fashion-MNIST (Xiao, Rasul y Vollgraf, 2017; licencia MIT), descargado con tf.keras; no se usa MovieLens. Validación: 6000 imágenes aleatorias del entrenamiento oficial (semilla 42, índices guardados); entrenamiento: 54 000; prueba: 10 000 oficiales, usadas solo para medir reconstrucción y como referencia de memoria. Líneas base: la imagen media (no aprende nada) y PCA con 16 componentes (compresión lineal del mismo tamaño que el AE). Se comparan con el AE y el VAE 2 del proyecto base y con un VAE de latente 16. Parada temprana sobre la pérdida de validación.


2. Tabla principal de resultados


Modelo	MSE píxel (test)	BCE imagen (test)	Pérdida valid.	Parámetros	Épocas	Segundos	KB
Imagen media	0.0866	385.0	—	784	—	0.0	—
PCA 16	0.0198	249.3	—	13,328	—	0.2	—
AE 16 (base)	0.0179	234.6	—	25,888	30	19.8	331
VAE 2 (base)	0.0292	258.0	262.9	202,516	40	41.2	833
VAE 16	0.0140	223.9	242.6	207,920	40	44.2	854

Decisión fijada en validación: VAE con menor pérdida total (reconstrucción + KL) en validación. Pérdida total en validación: vae_16=242.60, vae_2=262.92. Se elige la menor: vae_16. La pérdida total (reconstrucción + KL) es una cota de la verosimilitud y es comparable entre dimensiones latentes.


3. Reconstrucción, muestreo e interpolación

Reconstrucción de 12 imágenes de prueba




Muestras generadas desde $N(0, I)$ 

Interpolación Sneaker → Ankle boot (prueba)



El VAE 16 conserva la forma y parte de la textura; el VAE 2 produce siluetas borrosas. La interpolación entre un Sneaker y un Ankle boot reales pasa en el espacio latente por calzado plausible, mientras que la mezcla de píxeles superpone las dos imágenes.

Espacio latente del VAE 2 · prueba



En 2 dimensiones el calzado, los pantalones y los bolsos se separan; Pullover, Coat y Shirt se solapan, lo que explica por qué el VAE 2 no genera Pullover.

4. Fidelidad, diversidad y memoria

Conjunto	Confianza juez	Clases	Entropía	Dispersión	Dist. vecino train	Posibles copias
Real (prueba)	0.900	10	0.998	11.24	3.52	5.0 %
VAE 2 (base)	0.528	9	0.883	6.96	2.56	19.0 %
VAE 16	0.625	10	0.981	8.55	3.62	0.5 %

1000 muestras de $N(0, I)$ por modelo. **Fidelidad:** confianza de un clasificador juez entrenado solo con entrenamiento (exactitud 0.893 en prueba). **Diversidad:** clases cubiertas, entropía del reparto de clases (1 = uniforme) y distancia media entre pares. **Memoria:** distancia al vecino más cercano de entrenamiento; una posible copia es una muestra más cercana que el 95 % de las imágenes reales de prueba (umbral 1.96). El VAE 16 no memoriza (0.5 %). El 19 % del

VAE 2 no son copias de imágenes concretas: son prototipos simples y borrosos, cercanos a muchas prendas lisas.

5. Costo, límites y conclusión

El VAE 16 cuesta casi lo mismo que el VAE 2 (207 920 frente a 202 516 parámetros; 44 s frente a 41 s en CPU, Apple M1 Pro) y mejora reconstrucción, diversidad y memoria. Límites: las muestras siguen siendo menos nítidas que las reales (confianza 0.63 frente a 0.90); las medidas de fidelidad dependen del juez; una sola semilla; los modelos llegaron al máximo de épocas. Generar datos sintéticos no garantiza privacidad. Model Card completa en MODEL_CARD.md.

6. Pruebas automatizadas

12 pruebas, todas aprobadas (reports/pruebas.txt): 4 del proyecto base y 8 propias. Lista completa en docs/PRUEBAS.md.

#	Prueba	Qué comprueba	Por qué se hizo
1	test normalization contract <i>Proyecto base · Baseline AE y VAE reproducibles</i>	Las imágenes pasan de 0–255 a 0–1 con un canal (28×28×1) y superan la validación.	La pérdida BCE del VAE solo tiene sentido con píxeles entre 0 y 1.
2	test rejects wrong shape <i>Proyecto base · Baseline AE y VAE reproducibles</i>	Falla si una imagen no tiene forma 28×28×1.	Detiene el proceso antes de entrenar con datos mal cargados.
3	test autoencoder output contract <i>Proyecto base · Baseline AE y VAE reproducibles</i>	El autoencoder devuelve una imagen del mismo tamaño que la entrada.	Sin esto no se puede calcular el error de reconstrucción contra la original.
4	test decoder output contract <i>Proyecto base · Reconstrucción, muestreo e interpolación</i>	El decodificador convierte un punto latente en una imagen 28×28×1.	Es la pieza que genera muestras e interpolaciones.
5	test encoder returns mean and log variance with latent size <i>Nueva · Baseline AE y VAE reproducibles</i>	El codificador del VAE devuelve media y log-varianza del tamaño latente pedido (16).	El VAE necesita ambas salidas para el truco de reparametrización y la KL; con el tamaño equivocado la comparación VAE 2 vs VAE 16 no sería válida.
6	test vae losses are finite and kl is non negative <i>Nueva · Baseline AE y VAE reproducibles</i>	La reconstrucción es un número finito y la divergencia KL no es negativa.	La KL nunca puede ser negativa; si lo fuera, la pérdida estaría mal implementada y la decisión basada en ella sería inválida.
7	test validation split is disjoint complete and reproducible <i>Nueva · Baseline AE y VAE reproducibles</i>	Entrenamiento y validación no comparten imágenes, cubren todo el conjunto y la semilla 42 repite la misma partición.	El proyecto base usaba validation_split (las últimas imágenes, sin barajar) y el VAE no tenía validación; ahora la decisión se toma con una validación explícita y reproducible.
8	test reconstruction error is zero for perfect copy and grows with noise <i>Nueva · Reconstrucción, muestreo e interpolación</i>	El error es cero para una copia perfecta y aumenta si la reconstrucción es gris uniforme.	Confirma que la tabla de reconstrucción ordena bien a los modelos (media > PCA > AE > VAE 16).
9	test nearest distance detects a memorized copy <i>Nueva · Fidelidad, diversidad y memoria</i>	Una muestra idéntica a una imagen de entrenamiento tiene distancia 0 al vecino más cercano; una aleatoria no.	Es la base de la medida de memoria: si el modelo copiara imágenes de entrenamiento se detectaría.
10	test class diversity distinguishes collapse from variety <i>Nueva · Fidelidad, diversidad y memoria</i>	Si todas las muestras son de una clase la entropía es 0; si se reparten en 10 clases es 1.	Detecta el colapso de modos: un generador que solo produce una prenda tendría buena fidelidad pero cero diversidad.
11	test pairwise spread is zero when all samples are equal <i>Nueva · Fidelidad, diversidad y memoria</i>	La dispersión entre muestras es 0 cuando todas son iguales.	Segunda medida de diversidad que no depende del clasificador juez.
12	test choose prefers lower validation loss <i>Nueva · Costo, límites y conclusión</i>	La regla elige el VAE con menor pérdida total de validación.	Fija la decisión antes de mirar la prueba; la pérdida total (reconstrucción + KL) es comparable entre dimensiones latentes.

7. Uso de IA

Utilicé Claude Code (Claude Opus 5.5), Codex (OpenAI) y DeepSeek como apoyo. Con Claude Code adapté el proyecto base, añadí las líneas base, el VAE 16, la validación y las medidas de fidelidad, diversidad y memoria, y escribí las pruebas, el cuaderno y la redacción. Verifiqué que los modelos recargados reproducen las métricas, las figuras y las pruebas; se corrigió una prueba con tolerancia numérica incorrecta. Detalle en AI_USE_DECLARATION.md.

Herramienta	Modelo	Uso en esta práctica	Para qué sirve	Límite y control
Claude Code (Anthropic)	Claude Opus 5.5	Usado. Agente en VS Code: código, pruebas, cuaderno, documentación, ejecución y PDF	Tareas largas de varios pasos sobre un repositorio	Todo se verificó con pruebas y reportes
Claude (Anthropic)	Claude Sonnet 5	No usado	Programación cotidiana, equilibrio velocidad-calidad	Menos profundidad en tareas largas
Claude (Anthropic)	Claude Haiku 4.5	No usado	Tareas rápidas y baratas: resúmenes, clasificación	No indicado para diseño experimental
Codex (OpenAI)	Modelo de OpenAI orientado a código (familia GPT-5-Codex)	Apoyo complementario	Proponer y revisar código, explicar errores, sugerir pruebas	Se acepta solo si pasa las pruebas
DeepSeek	DeepSeek-V3 (chat)	Apoyo complementario	Explicar conceptos y revisar redacción	Puede inventar referencias: se verificaron en la fuente
DeepSeek	DeepSeek-R1 (razonamiento)	No usado; recomendado para revisar la lógica de métricas	Razonamiento paso a paso y depuración lógica	No sustituye la ejecución

Reparto de responsabilidades

Responsabilidad	Quién
Valores del análisis (daño prioritario, tolerancias, compuertas, decisiones de uso)	La autora
Elección de datos y verificación de licencias y referencias	La autora, con apoyo de las herramientas
Borradores de código, pruebas y redacción	Herramientas de IA
Ejecución de pruebas y comprobación de cada cifra contra reports/	La autora, con Claude Code
Defensa oral y respuesta a preguntas técnicas	La autora