

Ejercicio 07 · Evaluación de impacto y auditoría de equidad

Marlenis Judith Concepción Cuevas · INF-8239-C2 · Unidad IV · Docente: Edwin Ramón José Nolasco

Repositorio: <https://github.com/marlenis-concepcion/CienciaDatosUasd2026/tree/main/Ciencia%20de%20DatosII/Unidad%20IV/Ejercicio%2007>

Sistema: *Territorial Review DSS - Synthetic* (proyecto base del curso). Datos sintéticos: 640 casos, sin personas reales. El sistema ordena casos para revisión humana; no decide intervenciones.

1. Finalidad, interesados y proporcionalidad

Campo	Contenido
purpose	Ordenar los casos territoriales entrantes para que el equipo técnico revise primero los de mayor riesgo; el sistema no decide intervenciones.
assisted decision	Orden de revisión humana de casos (qué caso mira primero el analista). La intervención, elegibilidad o emergencia la decide siempre una persona con autoridad institucional.
users	Analistas territoriales que revisan casos y su supervisor de turno.
affected population	Personas y comunidades de las zonas Norte, Sur, Este y Oeste cuyos casos se registran; en especial el grupo G2 y las personas de 60+, con mayor exposición y menor puntuación de infraestructura en los datos.
owner	Responsable institucional del programa territorial (Product Owner); responde por la decisión de uso y el retiro del sistema.
non predictive alternative	Regla transparente sin modelo, priorizar si hay 4 o más incidentes previos o exposición mayor o igual a 0.6; y el orden de llegada como referencia mínima.
out of scope use	Decidir automáticamente intervenciones, elegibilidad para ayudas o declaratorias de emergencia; perfilar personas; usar el grupo protegido o la edad como criterio de decisión; aplicarlo a datos reales sin nueva evaluación.
withdrawal condition	Retirar o volver a la regla transparente si el recall baja de 0.68, si la brecha de recall o de FPR entre grupos supera 0.16 en dos revisiones mensuales seguidas, si aparece un incidente de discriminación confirmado o si cambia la población atendida.
appeal mechanism	Cualquier persona u organización comunitaria puede pedir revisión manual de la prioridad asignada por el canal institucional; un analista distinto revisa en 5 días hábiles y la respuesta queda registrada con su justificación.

Interesado	Beneficio	Daño	Poder	Participación
Affected person	Su caso de alto riesgo se revisa antes	Quedar al final de la cola por un falso negativo o ser revisado sin necesidad por un falso positivo	low	Canal de apelación y consulta comunitaria antes del piloto
Operator	Ordena la carga de trabajo con un criterio explícito	Sobrecarga si hay muchos falsos positivos; exceso de confianza en la lista (sesgo de automatización)	medium	Capacitación y registro de discrepancias con la lista sugerida
Institutional owner	Usa mejor el tiempo del equipo y documenta decisiones	Responsabilidad legal y reputacional si el sistema discrimina	high	Aprueba o retira el sistema y firma el registro de decisión
Data team	Mejora el sistema con evidencia y retroalimentación	Culpa por errores de datos o de modelo fuera de su control	medium	Mantiene auditorías y monitoreo; propone cambios
Community organizations	Transparencia sobre cómo se prioriza su zona	Estigmatización de zonas o grupos	low	Reciben el resumen de auditoría y pueden observar el piloto

Proporcionalidad. Necesidad: el volumen obliga a ordenar la revisión. Idoneidad: la regla transparente alcanza recall 0.75 en prueba. Menor intrusión: usa solo incidentes previos y exposición, sin edad, zona ni grupo. Equilibrio: envía más casos a revisión (FPR 0.37), aceptado porque el daño prioritario es el falso negativo; la carga se vigila (R06).

2. Obligación legal, marco voluntario y recomendación ética

Tipo	Fuente	Aplicación en este sistema
Obligación legal	Ley 172-13 de protección de datos personales (RD, 2013)	Con datos reales: finalidad declarada, datos mínimos; el esquema rechaza identificadores directos
Obligación legal	Constitución RD, arts. 39 (igualdad), 44 (intimidad) y 70 (hábeas data)	El grupo protegido no decide; no se perfila; apelación y rectificación documentadas
Marco voluntario	NIST AI RMF 1.0 (NIST AI 100-1, 2023)	Cada riesgo vinculado a una subcategoría de GOVERN, MAP, MEASURE o MANAGE
Marco voluntario	Model Cards (Mitchell et al., 2019); Datasheets (Gebreu et al., 2021)	Documentación de datos y modelo (se completa en el Ejercicio 08)
Recomendación ética	Criterio propio	Preferir la alternativa menos intrusiva si rinde igual; no decidir con celdas de menos de 30 casos; supervisión humana y apelación

Análisis académico, no asesoría jurídica. Matriz completa y referencias en docs/MARCO_NORMATIVO.md.

3. Registro de riesgos y NIST AI RMF

ID	Escenario	Pro b.	Imp .	Prioridad	Control	Responsable	NIST AI RMF
R0 1	Casos de alto riesgo del grupo G1 quedan al final de la cola (recall 0.65 frente a 0.79 de G2 con la regresión logística)	3	4	12	Auditoría por grupo con intervalo bootstrap y compuerta de brecha de recall; usar la regla transparente si la brecha no se reduce	Data Scientist	MEASURE 2.11
R0 2	Conclusiones sobre subgrupos pequeños (G2 45-59 tiene 8 casos en prueba) presentadas como definitivas	3	3	9	Marcar celdas con menos de 30 casos y no tomar decisiones con ellas; ampliar muestra en el piloto	Data Scientist	MAP 2.3
R0 7	Sesgo de automatización: el analista sigue la lista sin revisar	3	3	9	Mostrar las razones de la prioridad; registrar discrepancias; auditoría mensual de casos no priorizados	Institutional Owner	MAP 3.4
R0 3	Uso del sistema para decidir intervenciones o elegibilidad en lugar de ordenar revisiones	2	4	8	Usos prohibidos en configuración y en la aplicación; la decisión final la firma una persona	Institutional Owner	MAP 1.1
R0 4	Uso del grupo protegido o la edad como criterio de decisión (tratamiento diferenciado)	2	4	8	Excluir protected_group del modelo; descartar ThresholdOptimizer que lo requiere al decidir; conservarlo solo para auditar	Data Scientist	GOVERN 1.1
R0 8	Degradación o cambio de población después del despliegue	2	3	6	Monitoreo mensual de recall y brechas con umbrales de retiro; runbook de reversión (Ejercicio 08)	ML Engineer	MANAGE 4.1
R0 6	Sobrecarga del equipo por falsos positivos de la regla (FPR 0.37)	3	2	6	Medir casos marcados por semana y ajustar el umbral solo con validación y registro de cambio	Product Owner	MEASURE 2.8
R0 5	Filtración de identificadores directos al conjunto de datos	1	4	4	Contrato de esquema que rechaza name document_number email y phone; prueba automática	Data Engineer	MEASURE 2.10


Prioridad = probabilidad × impacto (1–4). Las subcategorías se contrastaron con el texto de NIST AI 100-1.

4. Auditoría global, por grupo e interseccional

Partición temporal del proyecto base: 480 casos de entrenamiento (los últimos 120 como validación) y 160 de prueba posteriores. El grupo protegido se excluye del modelo y se usa solo para auditar. Tasa base en prueba: 0.49 en G1 y 0.73 en G2; por eso la métrica principal es la igualdad de oportunidades (recall), no la paridad de selección.

Candidato	Recall valid.	Recall test	FPR test	Accuracy	Selección	Brecha recall	Brecha FPR	Brecha selección
regla_no_predictiva	0.828	0.750	0.368	0.700	0.588	0.011	0.010	0.090
logistica_0.50	0.812	0.717	0.279	0.719	0.531	0.138	0.125	0.232
arbol_0.50	0.781	0.717	0.309	0.706	0.544	0.181	0.168	0.266
logistica_0.56	0.812	0.696	0.191	0.744	0.481	0.135	0.077	0.231

Candidato	Recall valid.	Recall test	FPR test	Accuracy	Selección	Brecha recall	Brecha FPR	Brecha selección
threshold_optimizer_eo	0.750	0.804	0.441	0.700	0.650	0.069	0.168	0.009



Regla elegida por grupo y edad (prueba):

Grupo o edad	n	Recall	FPR	Precisión	Selección
G1	101	0.755	0.365	0.661	0.554
G2	59	0.744	0.375	0.842	0.644
18-29	29	0.833	0.529	0.526	0.655
30-44	38	0.750	0.300	0.875	0.632
45-59	43	0.739	0.250	0.773	0.512
60+	50	0.724	0.381	0.724	0.580

Interseccional (grupo × edad): 7 de 8 celdas tienen menos de 30 casos; sus valores no se usan para decidir.

Grupo edad	n	Recall	FPR	n ≥ 30
G1 18-29	18	0.750	0.500	no
G1 30-44	24	0.750	0.375	no
G1 45-59	35	0.706	0.278	sí
G1 60+	24	0.833	0.333	no
G2 18-29	11	0.875	0.667	no
G2 30-44	14	0.750	0.000	no
G2 45-59	8	0.833	0.000	no
G2 60+	26	0.647	0.444	no

Incertidumbre (bootstrap, 1000 remuestreos): brecha de recall de la regla entre 0.004 y 0.208; brecha de FPR entre 0.004 y 0.331. Para la regresión logística, la brecha de recall llega a 0.314.

5. Mitigación, trade-offs y decisión

Mitigaciones evaluadas: (a) umbral global ajustado en validación (0.56), que reduce la brecha de FPR pero baja el recall por debajo de 0.70; (b) ThresholdOptimizer de Fairlearn con igualdad de probabilidades, que reduce la brecha de recall a 0.07 pero sube el FPR a 0.44 y **necesita el grupo protegido al decidir**, por lo que se descarta (art. 39 de la Constitución y riesgo R04); (c) sustituir el modelo por la regla transparente.

Regla de elección fijada en validación: Cumplen las compuertas en validación: regla_no_predictiva, logistica_0.50, logistica_0.56. Se elige el de mayor recall: regla_no_predictiva. ThresholdOptimizer se excluye porque necesita el grupo protegido en el momento de decidir (tratamiento diferenciado explícito).

Decisión final: LIMITAR. La regla cumple las compuertas en prueba (recall 0.750, brechas 0.011 y 0.010), pero el extremo superior del intervalo supera la tolerancia de 0.16 y la mayoría de celdas interseccionales son pequeñas. Se usa la regla solo para ordenar revisiones humanas en un piloto limitado, con apelación y monitoreo mensual; **no se**

utiliza el modelo de regresión logística. Registro completo en reports/lab11/DECISION_RECORD.md.

6. Pruebas automatizadas

23 pruebas, todas aprobadas (reports/pruebas.txt): 10 del proyecto base y 13 propias. Lista en docs/PRUEBAS.md.

#	Prueba	Qué comprueba	Por qué se hizo
1	test dataset contract <i>Proyecto base · Finalidad, interesados y proporcionalidad</i>	El conjunto tiene al menos 500 casos y case_id es único.	Sin identificadores únicos no se puede trazar un caso ni atender una apelación.
2	test direct identifier rejected <i>Proyecto base · Finalidad, interesados y proporcionalidad</i>	El esquema rechaza una columna email.	Minimización: los identificadores directos no hacen falta para ordenar revisiones.
3	test prohibited name rejected <i>Proyecto base · Finalidad, interesados y proporcionalidad</i>	El esquema rechaza una columna name.	Refuerza la protección de datos exigida si se usaran datos reales (Ley 172-13).
4	test complete risk is scored <i>Proyecto base · Registro de riesgos y NIST AI RMF</i>	La prioridad de un riesgo es probabilidad × impacto.	El orden del registro decide qué controles se atienden primero.
5	test placeholder is rejected <i>Proyecto base · Registro de riesgos y NIST AI RMF</i>	Un riesgo con texto REPLACE no se acepta.	Evita entregar un registro con campos sin completar.
6	test fairness metrics are bounded <i>Proyecto base · Auditoría global, por grupo e interseccional</i>	La brecha de recall está entre 0 y 1 y existen los grupos G1 y G2.	Comprueba que la auditoría por grupo funciona sobre el modelo real.
7	test predictions are binary <i>Proyecto base · Auditoría global, por grupo e interseccional</i>	El modelo solo predice 0 o 1.	Las métricas de equidad asumen predicciones binarias.
8	test failed gate requires review <i>Proyecto base · Mitigación, trade-offs y decisión</i>	Si falla una compuerta el estado pasa a REVIEW.	Ningún sistema pasa a GO con una compuerta incumplida.
9	test raci requires accountable <i>Proyecto base · Mitigación, trade-offs y decisión</i>	Una actividad sin responsable A se rechaza.	Toda decisión necesita una persona que rinda cuentas.
10	test app starts and discloses synthetic case <i>Proyecto base · Finalidad, interesados y proporcionalidad</i>	La aplicación arranca y advierte que los datos son sintéticos.	Transparencia con quien la usa: no representa estadísticas reales.
11	test student impact assessment is complete <i>Nueva · Finalidad, interesados y proporcionalidad</i>	La evaluación de impacto no tiene campos vacíos y declara que el sistema solo asiste la revisión.	La finalidad limitada es la base de la proporcionalidad y de los usos prohibidos.
12	test risk register is complete and linked to nist rmf <i>Nueva · Registro de riesgos y NIST AI RMF</i>	Hay 8 riesgos o más, cada uno con una subcategoría válida del NIST AI RMF, cubriendo las cuatro funciones, ordenados por prioridad.	Demuestra que el registro está trazado al marco y no es una lista suelta.
13	test stakeholders include affected people without placeholders <i>Nueva · Finalidad, interesados y proporcionalidad</i>	El mapa de interesados incluye a las personas afectadas y está completo.	Las personas afectadas son las de menor poder y deben estar representadas.
14	test normative matrix separates legal voluntary and ethical <i>Nueva · Pruebas, referencias y declaración de IA</i>	La matriz normativa distingue obligación legal, marco voluntario y recomendación ética y cita la Ley 172-13 y el NIST AI 100-1.	Es un requisito explícito del mandato.
15	test protected attribute is not a model or rule input <i>Nueva · Mitigación, trade-offs y decisión</i>	Invertir el grupo protegido de todos los casos no cambia ninguna decisión de la regla.	Prueba de forma directa que no hay tratamiento diferenciado por grupo.
16	test bootstrap interval contains the observed gap <i>Nueva · Auditoría global, por grupo e interseccional</i>	El intervalo bootstrap de la brecha está ordenado y acotado entre 0 y 1.	La decisión de limitar depende de este intervalo.

#	Prueba	Qué comprueba	Por qué se hizo
17	test small intersectional cells are flagged <i>Nueva · Auditoría global, por grupo e interseccional</i>	Una celda con 8 casos se marca como insuficiente y una con 35 no.	Evita sacar conclusiones de subgrupos demasiado pequeños (riesgo R02).
18	test choice excludes threshold optimizer that uses protected group <i>Nueva · Mitigación, trade-offs y decisión</i>	La regla de elección descarta ThresholdOptimizer aunque tenga mejor recall.	Esa mitigación necesita el grupo protegido al decidir; se documenta pero no se elige.
19	test final decision maps evidence to four options[desplegar] <i>Nueva · Mitigación, trade-offs y decisión</i>	Con compuertas cumplidas y poca incertidumbre la decisión es desplegar.	Las cuatro opciones del mandato deben salir de reglas explícitas.
20	test final decision maps evidence to four options[limitar] <i>Nueva · Mitigación, trade-offs y decisión</i>	Si se cumplen las compuertas pero el intervalo supera la tolerancia, la decisión es limitar.	Es el caso de este ejercicio.
21	test final decision maps evidence to four options[modificar] <i>Nueva · Mitigación, trade-offs y decisión</i>	Si la brecha supera la tolerancia con recall suficiente, la decisión es modificar.	Obliga a mitigar antes de usar.
22	test final decision maps evidence to four options[no utilizar] <i>Nueva · Mitigación, trade-offs y decisión</i>	Si el recall no alcanza el mínimo, la decisión es no utilizar.	Un sistema que no encuentra los casos de riesgo no debe usarse.
23	test temporal split keeps future cases in test <i>Nueva · Auditoría global, por grupo e interseccional</i>	Todos los casos de prueba son posteriores a los de entrenamiento.	La auditoría simula el uso real: se entrena con el pasado y se evalúa con casos nuevos.

7. Referencias

Ley No. 172-13 sobre protección de datos personales (2013). · Constitución de la República Dominicana (2015), arts. 39, 44 y 70. · NIST (2023). AI RMF 1.0, NIST AI 100-1. doi:10.6028/NIST.AI.100-1 · Bird et al. (2020). Fairlearn, MSR-TR-2020-32. · Hardt, Price y Srebro (2016). Equality of Opportunity in Supervised Learning, NeurIPS. · Mitchell et al. (2019). Model Cards for Model Reporting, FAT*. · Gebru et al. (2021). Datasheets for Datasets, CACM 64(12).

8. Uso de IA

Utilicé Claude Code (Claude Opus 5.5), Codex (OpenAI) y DeepSeek como apoyo para estructura, código, pruebas y redacción. Los valores del análisis (daño prioritario, tolerancias, preferir la alternativa menos intrusiva, no usar el grupo protegido al decidir) son decisiones propias. Verifiqué las subcategorías del NIST AI RMF en el documento oficial y la Ley 172-13 y la Constitución en fuentes oficiales. Se corrigieron dos scripts del proyecto base que no ejecutaban. Detalle en docs/AI_USE_DECLARATION.md.

Herramienta	Modelo	Uso en esta práctica	Para qué sirve	Límite y control
Claude Code (Anthropic)	Claude Opus 5.5	Usado. Agente en VS Code: código, pruebas, cuaderno, documentación, ejecución y PDF	Tareas largas de varios pasos sobre un repositorio	Todo se verificó con pruebas y reportes
Claude (Anthropic)	Claude Sonnet 5	No usado	Programación cotidiana, equilibrio velocidad-calidad	Menos profundidad en tareas largas
Claude (Anthropic)	Claude Haiku 4.5	No usado	Tareas rápidas y baratas: resúmenes, clasificación	No indicado para diseño experimental
Codex (OpenAI)	Modelo de OpenAI orientado a código (familia GPT-5-Codex)	Apoyo complementario	Proponer y revisar código, explicar errores, sugerir pruebas	Se acepta solo si pasa las pruebas
DeepSeek	DeepSeek-V3 (chat)	Apoyo complementario	Explicar conceptos y revisar redacción	Puede inventar referencias: se verificaron en la fuente
DeepSeek	DeepSeek-R1 (razonamiento)	No usado; recomendado para revisar la lógica de métricas	Razonamiento paso a paso y depuración lógica	No sustituye la ejecución

Reparto de responsabilidades

Responsabilidad	Quién
Valores del análisis (daño prioritario, tolerancias, compuertas, decisiones de uso)	La autora
Elección de datos y verificación de licencias y referencias	La autora, con apoyo de las herramientas
Borradores de código, pruebas y redacción	Herramientas de IA
Ejecución de pruebas y comprobación de cada cifra contra reports/	La autora, con Claude Code
Defensa oral y respuesta a preguntas técnicas	La autora